# Er det høyde som bestemmer inntekt?

```
library(ggplot2)
library(tinytex)
library(tidyverse)
## -- Attaching packages ------ tidyverse 1.3.1 --
## v tibble 3.1.3 v dplyr 1.0.7
## v tidyr 1.1.3 v stringr 1.4.0
## v readr 2.0.1 v forcats 0.5.1
## v purrr 0.3.4
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag() masks stats::lag()
library(modelr)
library(ggpubr)
library(huxtable)
##
## Attaching package: 'huxtable'
## The following object is masked from 'package:ggpubr':
##
##
       font
## The following object is masked from 'package:dplyr':
##
       add_rownames
## The following object is masked from 'package:ggplot2':
##
##
       theme_grey
library(car)
## Loading required package: carData
## Attaching package: 'car'
```

```
## The following object is masked from 'package:dplyr':
##
## recode

## The following object is masked from 'package:purrr':
##
## some

library(carData)
options(scipen = 999)
```

### Kort innledning

Vi vil i denne oppgaven bruke datasettet *heights* for å undersøke riktigheten av påstanden om at høyde bestemmer inntekt. Undersøkelsen vil bli gjort gjennom analyser av ulike variabler og ved regresjonsanalyser. Resultatene vil bli fremstilt i ulike modeller, før vi vil avslutte med en konklusjon av spørsmålet "er det høyde som bestemmer inntekt?".

# Litteraturgjennomgang

# Analyse

```
hoyde <- heights
```

#### Beskrivende statestikk

Datasettet 'Heights' som har fått navnet 'hoyde' består opprinnelig av åtte variabler og 7006 observasjoner. Basert på disse variablene og observasjonene skal det være mulig å konkludere om ens inntekt bestemmes av høyde. Variablene som er inkludert i datasettet er: \* income - Basert på årlig inntekt, der topp to prosent er representert av gjennomsnittelig verdi av de to prosentene. \* height - Høyden til subjektene som har deltatt målt i inch. \* weight - Vekten til subjektene som har deltatt målt i pounds. \* age - Alderen til subjektene som har deltatt er mellom 47 og 56. \* martial - Subjektenes sivilstatus, om der gift eller skilt. \* sex - Subjektenes kjønn, mann eller kvinne. \* education - Subjektenes år med utdanning. \* afqt - Subjektenes poengsum i prosent på 'Armed Forces Qualification Test'

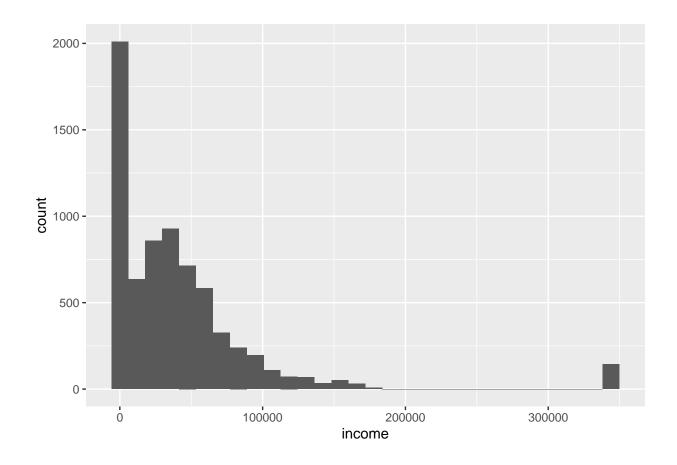
#### EDA

```
ggplot(data = hoyde)
```

# Lag et histogram av variablen income

```
ggplot(data = hoyde, aes(income)) +
  geom_histogram()
```

## 'stat\_bin()' using 'bins = 30'. Pick better value with 'binwidth'.



### Forklaringen på utliggerne langt til høyre

På modellen ser man at utliggeren som i dette tilfellet er ekstremalpunktet ligger langt til høyre. Dette er på grunn av at de har blitt regnet ut et gjennomsnitt av topp to prosentene av inntektene.

#### Personer uten inntekt inkludert i datasettet?

```
sum(hoyde$income == 0)
```

## [1] 1740

Det er altså 1740 av 7006 personer som har null i inntekt.

# Regresjonsanalyse

hoyde <- heights

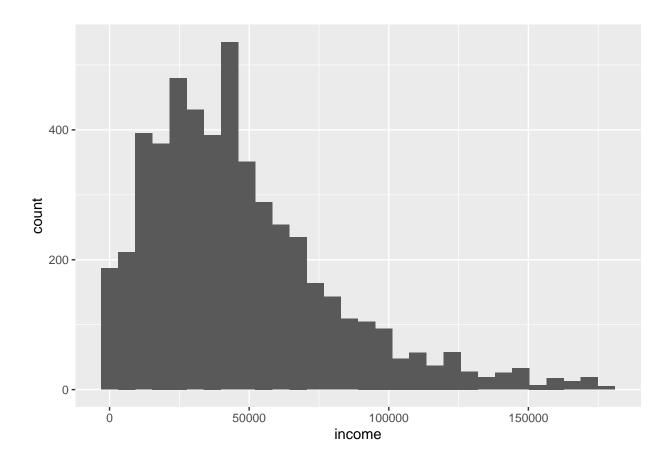
#### Dollar til norske kroner

```
hoyde <- hoyde %>%
  mutate(inntekt = income * 8.42)
```

Vi gjør Amerikanske dollar om til norske kroner. Valutakurens ligger på 8.42.

#### Redusert datasett

## 'stat\_bin()' using 'bins = 30'. Pick better value with 'binwidth'.



Lag to nye variabler + lag ny variabel "bmi"

```
hoyde <- hoyde %>%

mutate(hoyde_cm = height * 2.54,

vekt_kg = weight * 0.454,

BMI = (vekt_kg/hoyde_cm)^2)
```

#### Forenklet utgave av variabelen "Martial"

```
hoyde <- hoyde %>%
mutate(
  married = factor(
    case_when(
      marital == 'married' ~ TRUE,
      TRUE ~ FALSE
    )
  )
)
```

#### Minst 6 modeller

```
model1 <- "inntekt ~ hoyde_cm"</pre>
lm1 <- lm(model1, data = hoyde, subset = complete.cases(hoyde))</pre>
summary(lm1)
##
## lm(formula = model1, data = hoyde, subset = complete.cases(hoyde))
## Residuals:
      Min 1Q Median
                               3Q
## -782810 -267359 -94513 123099 2699234
## Coefficients:
                Estimate Std. Error t value
                                                       Pr(>|t|)
## (Intercept) -1361001.0 94430.0 -14.41 <0.0000000000000000 ***
                              552.8 18.18 < 0.0000000000000000 ***
## hoyde_cm
                 10047.9
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
## Residual standard error: 467300 on 6643 degrees of freedom
## Multiple R-squared: 0.04737,
                                   Adjusted R-squared: 0.04723
## F-statistic: 330.3 on 1 and 6643 DF, p-value: < 0.00000000000000022
#trenger vi å ta med dette??
-1337837.4 + (9884.6 *173)
```

```
-1337837.4 + (9884.6 *161)
## [1] 253583.2
Model2 <- "inntekt ~ hoyde_cm + vekt_kg"</pre>
lm2 <- lm(Model2, data = hoyde, subset = complete.cases(hoyde))</pre>
summary(lm2)
##
## Call:
## lm(formula = Model2, data = hoyde, subset = complete.cases(hoyde))
##
## Residuals:
      Min
              1Q Median
                              3Q
                                     Max
## -843668 -263322 -92573 125798 2715000
##
## Coefficients:
##
                Estimate Std. Error t value
                                                      Pr(>|t|)
## (Intercept) -1466873.6
                         96890.5 -15.139 < 0.0000000000000000 ***
## hoyde_cm
                           624.3 18.308 < 0.0000000000000000 ***
                11430.3
## vekt_kg
                 -1518.4
                             320.5 -4.737
                                                    0.00000221 ***
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
## Residual standard error: 466600 on 6642 degrees of freedom
## Multiple R-squared: 0.05058,
                                  Adjusted R-squared: 0.05029
## F-statistic: 176.9 on 2 and 6642 DF, p-value: < 0.000000000000000022
#Må vi ta med dette??
-697374.7 + (6735.7*173) + (-691.5*70)
## [1] 419496.4
Model3 <- "inntekt ~ hoyde_cm + vekt_kg + BMI"</pre>
lm3 <- lm(Model3, data = hoyde, subset = complete.cases(hoyde))</pre>
summary(lm3)
##
## lm(formula = Model3, data = hoyde, subset = complete.cases(hoyde))
##
## Residuals:
               1Q Median
##
      Min
                              ЗQ
                                     Max
## -810031 -262631 -92854 124005 2705975
##
## Coefficients:
              Estimate Std. Error t value
##
                                                    Pr(>|t|)
1184 7.951 0.00000000000000216 ***
## hoyde_cm
                 9413
                 2039
                           1803 1.131
                                                       0.258
## vekt_kg
                       268709 -2.005
             -538714
                                                       0.045 *
## BMI
```

```
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 466500 on 6641 degrees of freedom
## Multiple R-squared: 0.05115,
                                Adjusted R-squared: 0.05073
## F-statistic: 119.3 on 3 and 6641 DF, p-value: < 0.000000000000000022
# Slett denne
summary(hoyde_begr)
##
       income
                      height
                                     weight
                                                     age
                                Min. : 78.0
##
  \mathtt{Min.} :
              45
                  Min. :52.00
                                              Min. :47.00
  1st Qu.: 23000
                  1st Qu.:64.00
                                 1st Qu.:159.0
                                               1st Qu.:49.00
##
                  Median :67.00
                                Median :185.0 Median :51.00
## Median : 40000
## Mean : 46751
                                Mean :188.4 Mean :51.28
                  Mean :67.22
## 3rd Qu.: 62000
                  3rd Qu.:70.00
                                 3rd Qu.:212.0 3rd Qu.:53.00
## Max. :178000
                  Max. :80.00 Max. :480.0 Max. :56.00
##
                                      :69
                                 NA's
##
                                 education
       marital
                                                  afqt
                      sex
                  male :2526 Min. : 1.00 Min. : 0.00
## single : 699
                               1st Qu.:12.00 1st Qu.: 19.55
## married :2983
                  female:2597
## separated: 233
                               Median: 12.00 Median: 41.71
## divorced :1102
                               Mean
                                    :13.48
                                              Mean : 44.40
## widowed : 106
                               3rd Qu.:16.00
                                              3rd Qu.: 67.89
##
                               Max. :20.00
                                              Max. :100.00
##
                               NA's
                                      :2
                                              NA's
                                                     :184
##
      inntekt
## Min. :
              378.9
## 1st Qu.: 193660.0
## Median: 336800.0
## Mean : 393646.3
## 3rd Qu.: 522040.0
## Max. :1498760.0
##
```

# Huxreg

```
huxreg (list
  ("model1" = lm1, "model2" = lm2, "model3" = lm3),
        error_format = "[{statistic}]",
        note = "Regresjonstabell 3: {stars}.T statistics in brackets."
)
```

# Interaksjon

```
# Riktig, fjern denne linjen.
Model4 <- "inntekt ~ sex*hoyde_cm + vekt_kg + I(vekt_kg^2) + BMI + I(BMI^2)"
```

-			
	model1	model2	model3
(Intercept)	-1361000.990 ***	-1466873.555 ***	-1286217.908 ***
	[-14.413]	[-15.139]	[-9.722]
hoyde_cm	10047.860 ***	11430.259 ***	9413.347 ***
	[18.175]	[18.308]	[7.951]
vekt_kg		-1518.381 ***	2039.260
		[-4.737]	[1.131]
BMI			-538714.354 *
			[-2.005]
N	6645	6645	6645
R2	0.047	0.051	0.051
logLik	-96177.211	-96166.004	-96163.994
AIC	192360.423	192340.008	192337.987

Regresjonstabell 3: \*\*\* p < 0.001; \*\* p < 0.01; \* p < 0.05.T statistics in brackets.

```
lm4 <- lm(Model4, data = hoyde)
summary(lm4)</pre>
```

```
##
## lm(formula = Model4, data = hoyde)
## Residuals:
       Min
                1Q Median
                                3Q
                                       Max
## -838791 -246526 -91148 127011 2671450
##
## Coefficients:
                         Estimate Std. Error t value
                                                         Pr(>|t|)
## (Intercept)
                      -1483862.35
                                    298212.30 -4.976 0.000000665 ***
## sexfemale
                      1013185.90
                                    267052.10
                                               3.794
                                                          0.00015 ***
## hoyde_cm
                          9605.99
                                      2224.53
                                                4.318 0.000015950 ***
## vekt_kg
                          7666.44
                                      4523.70
                                                1.695
                                                          0.09017 .
## I(vekt_kg^2)
                          -41.62
                                        15.13 -2.752
                                                          0.00594 **
                                    743591.63 -0.772
## BMI
                       -574174.60
                                                          0.44004
## I(BMI^2)
                       508980.64
                                    335754.40
                                               1.516
                                                          0.12958
## sexfemale:hoyde_cm
                        -6597.83
                                      1566.60 -4.212 0.000025683 ***
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
## Residual standard error: 458400 on 6903 degrees of freedom
     (95 observations deleted due to missingness)
```

```
## Multiple R-squared: 0.06121, Adjusted R-squared: 0.06026
## F-statistic: 64.3 on 7 and 6903 DF, p-value: < 0.00000000000000022
Model5 <- "inntekt ~ sex*(hoyde_cm + vekt_kg + I(vekt_kg^2)) + BMI + I(BMI^2)"
lm5 <- lm(Model5, data = hoyde)</pre>
summary(lm4)
##
## Call:
## lm(formula = Model4, data = hoyde)
## Residuals:
##
      Min
               1Q Median
                              3Q
                                     Max
## -838791 -246526 -91148 127011 2671450
##
## Coefficients:
##
                       Estimate Std. Error t value
                                                      Pr(>|t|)
## (Intercept)
                    -1483862.35 298212.30 -4.976 0.000000665 ***
                                  267052.10 3.794
## sexfemale
                                                       0.00015 ***
                    1013185.90
                                    2224.53 4.318 0.000015950 ***
## hoyde_cm
                        9605.99
## vekt_kg
                        7666.44
                                    4523.70 1.695
                                                       0.09017 .
## I(vekt_kg^2)
                         -41.62
                                      15.13 -2.752
                                                       0.00594 **
                      -574174.60 743591.63 -0.772
## BMI
                                                       0.44004
## I(BMI^2)
                      508980.64 335754.40 1.516
                                                       0.12958
## sexfemale:hoyde_cm -6597.83
                                  1566.60 -4.212 0.000025683 ***
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
## Residual standard error: 458400 on 6903 degrees of freedom
    (95 observations deleted due to missingness)
## Multiple R-squared: 0.06121,
                                  Adjusted R-squared: 0.06026
## F-statistic: 64.3 on 7 and 6903 DF, p-value: < 0.00000000000000022
```

#### Test av koeffisientene

```
linearHypothesis(lm4, c("sexfemale = 0", "sexfemale:hoyde_cm = 0"))
```

Res.Df	RSS	$\mathbf{Df}$	Sum of Sq	$\mathbf{F}$	$\Pr(>F)$
6.90e+03	1.46e + 15				
6.9e+03	1.45e + 15	2	1.37e + 13	32.5	8.64e-15

# Begrensing

```
Model6 <- "inntekt ~ sex*hoyde_cm + vekt_kg + I(vekt_kg^2) + BMI + I(BMI^2)"
lm6 <- lm(Model6, data = hoyde)</pre>
summary(lm6)
##
## Call:
## lm(formula = Model6, data = hoyde)
## Residuals:
##
      Min
               1Q Median
                               30
## -838791 -246526 -91148 127011 2671450
## Coefficients:
                        Estimate Std. Error t value
                                                        Pr(>|t|)
## (Intercept)
                     -1483862.35 298212.30 -4.976 0.000000665 ***
## sexfemale
                                   267052.10 3.794
                     1013185.90
                                                         0.00015 ***
## hoyde_cm
                                     2224.53 4.318 0.000015950 ***
                         9605.99
## vekt_kg
                         7666.44
                                     4523.70 1.695
                                                         0.09017 .
                                                         0.00594 **
## I(vekt_kg^2)
                          -41.62
                                       15.13 -2.752
## BMI
                      -574174.60
                                   743591.63 -0.772
                                                         0.44004
## I(BMI^2)
                       508980.64
                                   335754.40 1.516
                                                         0.12958
## sexfemale:hoyde_cm
                        -6597.83
                                     1566.60 -4.212 0.000025683 ***
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 458400 on 6903 degrees of freedom
    (95 observations deleted due to missingness)
## Multiple R-squared: 0.06121,
                                   Adjusted R-squared: 0.06026
## F-statistic: 64.3 on 7 and 6903 DF, p-value: < 0.00000000000000022
```

### Legge til resiudalene til datasettet

```
# Bruk verdiene fra begrenset datasett
hoyde_begr <- hoyde %>%
  add_residuals(lm6)
hoyde_begr %>%
  head(n=10)
```

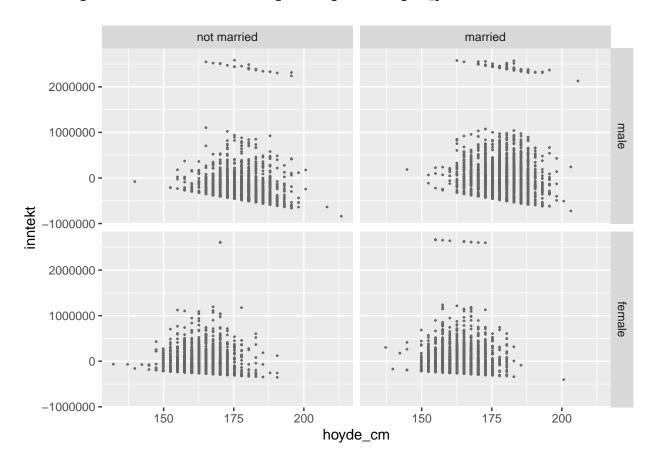
# Plot av samtilige observasjoner

```
ggplot(data = hoyde_begr, mapping = aes(x = hoyde_cm, y = inntekt)) +
geom_point(
  data = hoyde_begr,
  mapping = aes(x = hoyde_cm, y = resid),
  colour = "grey40",
  size = 0.3
```

${ m eight}$	weight	age	marital	sex	education	afqt	inntekt	$hoyde\_cm$	$vekt\_kg$	BMI	married
60	155	53	married	female	13	6.84	1.6e + 05	152	70.4	0.213	TRUE
70	156	51	married	female	10	49.4	2.95e + 05	178	70.8	0.159	TRUE
65	195	52	married	male	16	99.4	8.84e + 05	165	88.5	0.288	TRUE
63	197	54	married	female	14	44	3.37e + 05	160	89.4	0.312	TRUE
66	190	49	married	male	14	59.7	6.32e + 05	168	86.3	0.265	TRUE
68	200	49	divorced	female	18	98.8	8.59e + 05	173	90.8	0.276	FALSE
74	225	48	married	male	16	82.3	0	188	102	0.295	TRUE
64	160	54	divorced	female	12	50.3	5.89e + 05	163	72.6	0.2	FALSE
69	162	55	divorced	male	12	89.7	5.05e + 05	175	73.5	0.176	FALSE
69	194	54	divorced	male	13	96	1.26e + 06	175	88.1	0.253	FALSE

```
) +
facet_grid(sex ~ factor(married, labels = c("not married", "married")))
```

## Warning: Removed 95 rows containing missing values (geom\_point).



# Konklusjon